

■ FP16   
 ■ INT8   
 ■ INT4   
 ● Standard decoding   
 ▲ Speculative decoding   
 - - - Pareto front   
 ○ 7B-INT4 tracker

